

Efficient Micro-services architecture for Real Time Point Clouds Adaptive Streaming

Tiziana Cattai, Stefania Colonnese, Paolo Giannitrapani, Marco Listanti, Marco Polverini

Department of Information engineering, Electronics and Telecommunications (DIET)
University of Roma "Sapienza" - Via Eudossiana 18, 00184 Roma, Italy
Telephone: +39 0644585371, e-mail: name.surname@uniroma1.it

Abstract—bla bla bla ...

Index Terms—Point Cloud, Extended Reality

I. INTRODUCTION

Punti toccati nella riunione:

IDEE per lavori

- **creare un generatore di traffico da integrare in simulatori ed emulatori di rete**, basato sul modello di sorgente definito in [1];

- **definizione di un'architettura a micro servizi per la realizzazione del servizio di live streaming di point clouds**. La possibile novità è rappresentata dal fatto di considerare diverse tipologie di utenti finali, potenzialmente interessati a contenuti semantici diversi (es. live video, presenza di oggetti specifici, etc.); **con Andrea abbiamo lavorato a profili di utenti basati su aspetti tecnici e sociologici che impattano sulla qualità percepita vedi figura 1 e potrebbero guidare nell'allocazione del bit-rate e in generale delle risorse [2]**.




Figure 5: Key factors affecting the quality perceived by the user.




Figure 6: The Quality Experience Wheel as a "quality signature" of the XR services.

Figure 1. QoE wheel dal paper [2]

La Fig. 3 mostra la tipica pipeline di processing relativa alla trasmissione di Point Clouds. Questa è costituita dalle seguenti quattro funzioni: i) encoder, ii) transcoder, iii) decoder, iv) renderind. Una spiegazione dettagliata di queste funzioni è




Figure 2. Enter Caption

disponibile in [3]. Complessivamente possono essere individuate 5 interfacce tra i vari blocchi funzionali della pipeline, le cui caratteristiche sono riassunte in Tab. I.




Figure 3. SFC per streaming PCs con diverse opzioni di placement.

In ottica micro-servizi, la Fig. 3 mostra delle possibili soluzioni di placement delle singole funzioni che compongono la pipeline.

Interfaccia	Tipo file / flusso	Bit rate tipico
1	Point cloud raw (.ply, .bin)	1–10 Gbps
2	Stream compresso (V-PCC, G-PCC)	5–50 Mbps
3	Stream compresso adattato	1–20 Mbps
4	Point cloud decodificata	2–8 Gbps
5	Flusso video (stereo, 2D/3D o olografico)	100–800 Mbps

Table I
INTERFACCE FUNZIONALI NELLA PIPELINE OLOGRAFICA: TIPO DI DATI E
BIT RATE STIMATO

- **realizzazione di una tecnica AQM-like per l'adaptive streaming di point clouds**. A tale scopo, ho trovato questo lavoro [4], che introduce il protocollo Big Packet Protocol (BPP) per realizzare in network quality adaptation, mostrando

come questo consenta di ottenere prestazioni migliori di HAS in termini di QoE. Inoltre si adatta perfettamente al concetto di architettura a micro servizi (di fatto si può interpretare come il blocco di transcoding in Fig. 3). In questo caso, uno dei possibili vantaggi è che si può utilizzare anche un instradamento multicast, riducendo ulteriormente il carico in rete (vedi Fig. 4). Ci sono una serie di problemi aperti, come ad esempio l'encoding della PC con tecnica Scalable Video Coding (SVC), oltre che la definizione di algoritmi per identificare l'albero di distribuzione (inclusendo anche il placement dei packet washing), e l'ideazione di un packet washing implementabile in P4.




Figure 4. Dynamic In Network Adaptation tramite BPP.

Durante la call abbiamo esplorato la possibilità di eseguire il drop di un intero pacchetto anziché una parte di esso. Dal punto di vista del networking, il concetto è analogo, cioè adattare il rate del flusso direttamente in rete, anziché intervenire con meccanismi end-to-end, che risultano poco reattivi (specie in reti WAN). In entrambi i casi, occorre definire nuove soluzioni di encoding (abbiamo accennato all'uso del compressed sensing);

mi viene in mente un altro punto potenzialmente interessante. Credo che nella pipeline di processing dello streaming real time di point cloud, un collo di bottiglia importante dal punto di vista del delay è la funzione di encoding. Maggiore è la qualità di encoding, maggiore sarà il tempo necessario. Allora mi viene in mente che, se la rete comunica il bitrate massimo attualmente supportabile, si può istruire l'encoder per diminuire temporaneamente la qualità massima. Secondo voi ha senso?

Si, questo è un punto molto importante. I tempi di encoding/-decoding sono il vero problema della lentezza della struttura. Quindi, avere il bitrate sarà un bel valore aggiunto.

Inoltre, vi ho condiviso un file, nella cartella "appunti", che contiene alcuni problemi che avevo cominciato ad affrontare mesi fa e che sicuramente impattano questo progetto (gli studi sono stati interrotti per dare precedenza ad altri lavori). In particolare, vi suggerisco il paragrafo che parte dal filtro MAHF (di Tiziana e Stefania) per arrivare alla scelta del bitrate in base alla qualità percepita (che non è quella oggettiva). Si può risparmiare molta informazione, mantenendo la qualità apparente alta. E' tutto da verificare, sono solo prime impostazioni.

II. RELATED WORK

[1] definisce un modello di sorgente per le PCs.

[5]

[3]

[6] e [7] studiano il problema del live streaming di PCs in comunicazioni one-to-many e many-to-many, proponendo l'uso di una funzione di adaptive quality per regolare il bitrate del flusso in funzione della qualità della connessione dei singoli utenti.

[8] [9] [10]

[11], [12] definiscono la catena di servizi utilizzata per lo streaming di una PC. In particolare questa è definita dalle seguenti funzioni: i) encoding, ii) transcoding, iii) decoding, e iv) rendering. Inoltre apre alla possibilità di fare transcoding attraverso l'In Network Computing in P4. Gli articoli presentano un'architettura per la creazione di network slices per lo streaming di PCs. [13] [14] [15]

i seguenti articoli trattano dei modelli di diffusione su sistemi complessi, utilizzando grafi e strutture topologiche avanzate come complessi simpliciali e campi di Markov topologici. Estende i classici modelli di diffusione dai grafi a interazioni multidimensionali, permettendo di rappresentare come segnali, informazioni o energia si propagano su nodi, spigoli, facce o volumi. Vengono introdotti strumenti matematici come il Laplaciano di Hodge per modellare diffusione scalare e flussi in spazi topologicamente strutturati. I campi di Markov topologici descrivono dipendenze locali basate sulla topologia del dominio, consentendo di catturare fenomeni stocastici complessi in mesh, superfici o varietà. Il lavoro si collega anche a problematiche pratiche nella gestione di dati 3D, come compressione, trasmissione, qualità e denoising, mostrando come i concetti teorici possano essere applicati a dati strutturati e topologicamente ricchi. [16]

[17]

[18]

[19]

[20]

[21]

[22]

[23]

[24]

[25]

[26]

[27]

Negli ultimi anni, la ricerca sullo streaming di point cloud 3D ha compiuto passi significativi lungo quattro principali direttrici: codifica adattiva e compressione neurale, trasporto a bassa latenza, architetture distribuite edge/in-network, e valutazione percettiva e sperimentazioni reali.

Codifica adattiva e compressione neurale

Le sfide legate all'enorme volume di dati generato dai contenuti volumetrici hanno spinto lo sviluppo di nuovi codec intelligenti e scalabili. Il lavoro di Liang et al. [28] introduce Fumos, un framework di compressione neurale (N-PCC) abbinato a streaming progressivo: la scena è trasmessa inizialmente in forma base e successivamente

raffinata tramite layer incrementali, riducendo drasticamente il bitrate (-91.7% rispetto a $G - PCC$) e accelerando la decodifica di oltre $200\times$ rispetto a codec tradizionali come Draco. Analogamente, Haseeb et al. [29] presentano Octavius, un sistema di transcoding adattivo basato su octree pruning e trasporto QUIC con affidabilità mista, che regola in tempo reale la quantità di dettagli trasmessi in funzione della capacità di rete. Questa strategia elimina la necessità di multiple copie pre-codificate, ottenendo una scalabilità continua del bitrate e una latenza di consegna ridotta anche in condizioni di perdita.

Trasporto e protocolli a bassa latenza

Sul fronte dei protocolli, l'attenzione si è spostata verso soluzioni push-based su QUIC, in grado di superare le limitazioni del modello HTTP segmentato. Freeman et al. [30] propongono l'uso del protocollo Media over QUIC (MoQ) con Multiple Description Coding (MDC) per realizzare un adattamento implicito lato server. Il relay MoQ invia automaticamente un numero variabile di descrizioni per ogni frame, in base al budget di latenza del client, ottenendo un incremento di throughput del $90,8\%$ e un miglioramento di qualità percettiva (PCQM $+0.0024$) rispetto a DASH. Parallelamente, Denizer et al. [31] introducono FrameTrace, un sistema di telemetria frame-level per analizzare con precisione la latenza di codifica, rete e rendering. L'esperimento mostra che MoQ riduce la latenza fino all' 83% rispetto a Low-Latency DASH, e che l'adattamento dinamico del Group of Pictures (GoP) migliora il punteggio VMAF del 30% , riducendo stalli e buffering.

Architetture distribuite e in-network computing

Un'altra linea di sviluppo riguarda la collocazione dell'intelligenza di streaming all'interno della rete, sfruttando il paradigma edge e la programmabilità del data plane. Konstantoudakis et al. [32] propongono un'architettura serverless edge-based in ambiente 5G, in cui funzioni FaaS (Function-as-a-Service) gestiscono in modo elastico il transcoding multiutente, ottimizzando il rapporto QoE/costo e riducendo il consumo di risorse fino al 30% . In modo complementare, Krishna et al. [33] presentano NetSplat, che utilizza switch programmabili P4 per coordinare multicast dinamico e scheduling adattivo nello streaming di scene 3D Gaussian Splatting. Il data plane assume così un ruolo attivo nel controllo della qualità e della latenza, adattando in tempo reale la trasmissione ai diversi gruppi di utenti. Enenche et al. [34], in una rassegna su ICT Express, estendono questo concetto identificando i principali enabler tecnologici per il metaverso, tra cui Mobile Edge Computing (MEC), network coding e DPDK, come strumenti fondamentali per migliorare scalabilità, affidabilità e latenza nello streaming volumetrico.

Metriche di qualità e valutazione percettiva

La valutazione oggettiva e soggettiva della qualità delle point cloud dinamiche rappresenta un tema ancora aperto. Chazerand et al. [35] offrono una revisione sistematica sulle metriche di Quality of Experience (QoE) per point cloud, confrontando indicatori classici (PSNR, point-to-plane) con metriche percettive avanzate come PCQM e GraphSIM. Il lavoro evidenzia la necessità di modelli AI-based capaci di

correlare meglio i parametri di rete (bitrate, perdita, latenza) con la qualità percepita dall'utente.

Sperimentazioni reali e streaming su reti 5G

Infine, due lavori recenti validano sperimentalmente i limiti e le potenzialità dello streaming real-time su reti mobili. Ishimaru et al. [36] dimostrano la fattibilità di un sistema QoS-aware per point cloud live in scenari VR metaverse, in cui la qualità di ogni segmento anatomico viene regolata in base al movimento e alla connessione, mantenendo un'elevata fluidità e una QoE stabile anche su rete cellulare. Thomas e Xylomenos [37] presentano un'implementazione end-to-end su rete 5G privata, combinando acquisizione RealSense, compressione Draco, trasporto UDP custom e rendering OpenGL. I risultati mostrano latenze end-to-end comprese tra 50 e 120 ms e throughput sostenuto di 160 Mb/s, ma anche la necessità di adattamento aggressivo per evitare congestione e perdite di pacchetti.

REFERENCES

- [1] L. Mastrandrea, A. Priviero, G. Scarano, S. Colonnese, and T. Cattai, "Simulating extended reality traffic: An empirical model from user behavior to network packets," *Computer Communications*, p. 108244, 2025.
- [2] P. Panarese, A. Baiocchi, and S. Colonnese, "The extended reality quality riddle: A technological and sociological survey," in *2023 International Symposium on Image and Signal Processing and Analysis (ISPA)*, 2023, pp. 1–6.
- [3] J. Van Der Hooft, H. Amirpour, M. T. Vega, Y. Sanchez, R. Schatz, T. Schierl, and C. Timmerer, "A tutorial on immersive video delivery: From omnidirectional video to holography," *IEEE Communications Surveys & Tutorials*, vol. 25, no. 2, pp. 1336–1375, 2023.
- [4] S. Clayman, M. Tüker, E. Karakiş, and M. Sayit, "In-network video quality adaption using packet trimming at the edge," in *2023 26th Conference on Innovation in Clouds, Internet and Networks and Workshops (ICIN)*. IEEE, 2023, pp. 161–168.
- [5] A. Clemm, M. T. Vega, H. K. Ravuri, T. Wauters, and F. De Turck, "Toward truly immersive holographic-type communication: Challenges and solutions," *IEEE Communications Magazine*, vol. 58, no. 1, pp. 93–99, 2020.
- [6] M. De Fré, J. van der Hooft, T. Wauters, and F. De Turck, "Scalable mdc-based volumetric video delivery for real-time one-to-many webRTC conferencing," in *Proceedings of the 15th ACM multimedia systems conference*, 2024, pp. 121–131.
- [7] —, "Demonstrating adaptive many-to-many immersive teleconferencing for volumetric video," in *Proceedings of the 15th ACM Multimedia Systems Conference*, 2024, pp. 453–458.
- [8] J. Li, C. Zhang, Z. Liu, W. Sun, W. Hu, and Q. Li, "Demo abstract: Narwhal: A dash-based point cloud video streaming system over wireless networks," in *IEEE INFOCOM 2020-IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS)*. IEEE, 2020, pp. 1326–1327.
- [9] Z. Liu, Q. Li, X. Chen, C. Wu, S. Ishihara, J. Li, and Y. Ji, "Point cloud video streaming: Challenges and solutions," *IEEE Network*, vol. 35, no. 5, pp. 202–209, 2021.
- [10] M. Hosseini and C. Timmerer, "Dynamic adaptive point cloud streaming," in *Proceedings of the 23rd Packet Video Workshop*, 2018, pp. 25–30.
- [11] F. Aghaaliakbari, F. G. Javid, Z. Tasnim, Z. Ait Hmimi, M. Gherari, R. H. Glitho, and H. Elbiaze, "Demonstration of an in-network computing enabled architecture for holographic streaming," in *2022 IEEE Conference on Network Function Virtualization and Software Defined Networks (NFV-SDN)*. IEEE, 2022, pp. 101–102.
- [12] F. Aghaaliakbari, Z. Ait Hmimi, M. Rayani, M. Gherari, R. H. Glitho, H. Elbiaze, and W. Ajib, "An architecture for provisioning in-network computing-enabled slices for holographic applications in next-generation networks," *IEEE Communications Magazine*, vol. 61, no. 3, pp. 52–58, 2023.

- [13] C. Udora, P. Qian, S. Anmulwar, A. Fernando, and N. Wang, "Quality of experience modelling and analysis for live holographic teleportation," in *2024 International Conference on Computing, Networking and Communications (ICNC)*. IEEE Computer Society, 2024, pp. 598–604.
- [14] A. T. Da Silva, R. P. S. Clerici, F. E. R. Cesen, M. T. Islam, and C. E. Rothenberg, "Programmable network testbed for qos/qoe assessment of holographic media delivery," in *2024 IEEE Conference on Network Function Virtualization and Software Defined Networks (NFV-SDN)*. IEEE, 2024, pp. 1–2.
- [15] A. T. Da Silva, F. E. R. Cesen, M. T. Islam, R. P. S. Clerici, V. Testoni, and C. E. Rothenberg, "Assessing qoe in edge-delivered holographic streaming with a programmable hardware testbed," in *2025 IEEE 11th International Conference on Network Softwarization (NetSoft)*. IEEE, 2025, pp. 321–323.
- [16] G. Eason, B. Noble, and I. N. Sneddon, "On certain integrals of lipschitz-hankel type involving products of bessel functions," *Phil. Trans. Roy. Soc. London*, vol. A247, pp. 529–551, Apr. 1955.
- [17] J. C. Maxwell, *A Treatise on Electricity and Magnetism*, 3rd ed. Oxford: Clarendon, 1892, vol. 2.
- [18] I. S. Jacobs and C. P. Bean, "Fine particles, thin films and exchange anisotropy," in *Magnetism*, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, vol. III, pp. 271–350.
- [19] K. Elissa, "Title of paper if known," unpublished.
- [20] R. Nicole, "Title of paper with only first word capitalized," *J. Name Stand. Abbrev.*, in press.
- [21] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, "Electron spectroscopy studies on magneto-optical media and plastic substrate interface," *IEEE Transl. J. Magn. Japan*, vol. 2, pp. 740–741, Aug. 1987, [Digests 9th Annual Conf. Magnetism Japan, p. 301, 1982].
- [22] M. Young, *The Technical Writer's Handbook*. Mill Valley, CA: University Science, 1989.
- [23] P. Hou and et al., "A quality-aware sampling framework for efficient 3d point cloud transmission," in *ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2025, pp. 1–5.
- [24] W. J. Beksi and N. Papanikolopoulos, "A topology-based descriptor for 3d point cloud modeling: Theory and experiments," *Image and Vision Computing*, vol. 88, pp. 84–95, 2019.
- [25] Y. Xu and et al., "Compressed point cloud quality index by combining global appearance and local details," *ACM Transactions on Multimedia Computing, Communications and Applications*, vol. 20, no. 9, pp. 1–22, 2024.
- [26] J. Zhang and et al., "Efficient point cloud attribute compression framework using attribute-guided graph fourier transform," in *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2024, pp. 8426–8430.
- [27] W. Hu and et al., "Feature graph learning for 3d point cloud denoising," *IEEE Transactions on Signal Processing*, vol. 68, pp. 2841–2856, 2020.
- [28] Z. Liang et al., "Fumos: Neural compression and progressive refinement for continuous point cloud video streaming," *IEEE Transactions on Visualization and Computer Graphics (TVCG)*, 2024, accepted.
- [29] M. Haseeb et al., "Octavius: Towards efficient transmission of 3d point clouds via adaptive encoding and quic," in *ACM SIGCOMM Workshops*, 2025.
- [30] A. C. Freeman et al., "Point cloud streaming with latency-driven implicit adaptation using moq," *arXiv preprint*, 2025.
- [31] B. Denizer et al., "Frametrace: Frame-level telemetry for media over quic," in *ACM SIGCOMM Workshops*, 2025.
- [32] Konstantoudakis et al., "Serverless streaming for emerging media: 5g network-driven cost optimization (faas for immersive media)," *Multimedia Tools and Applications*, 2022.
- [33] N. B. Krishna et al., "Netsplat: Data plane network assistance for streaming 3d gaussian splatting scenes," in *ACM SIGCOMM Workshops*, 2025.
- [34] P. Enenche et al., "On the road to the metaverse: Point cloud video streaming – perspectives and enablers," *ICT Express*, vol. 11, 2025.
- [35] M. Chazerand et al., "New challenges in point cloud visual quality assessment: A systematic review," *Frontiers in Signal Processing*, 2024.
- [36] H. Ishimaru et al., "A qos-aware 3d point cloud streaming from real space for interaction in metaverse," in *IEEE PerCom Workshops*, 2023.
- [37] Y. Thomas and G. Xylomenos, "Ultra-low latency point cloud streaming in 5g," in *MMM*, 2023.